Прогнозирование оттока клиентов телеком-компании

- **Тема проекта:** Прогнозирование оттока клиентов телеком-компании
- **Формулировка задачи:** Разработка системы бинарной классификации для выявления абонентов, склонных к отказу от услуг связи. Задача имеет высокую значимость в социально-экономической сфере, так как направлена на улучшение качества обслуживания и удержание пользователей.

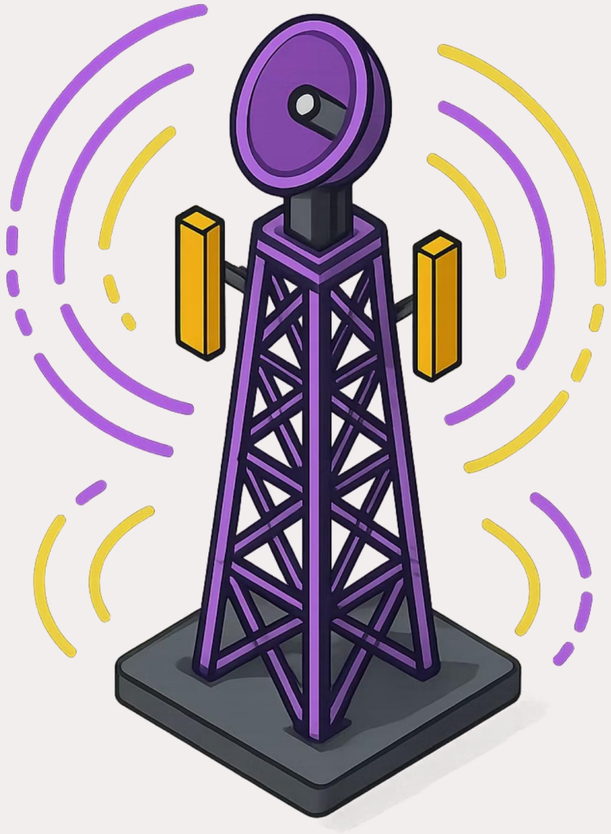

Актуальность и цель

Зачем это нужно?

Привлечение нового абонента обходится компании в 5-10 раз дороже, чем удержание текущего. Потеря клиентов напрямую бьет по выручке.

Цель:

Разработать автоматизированный инструмент, который по профилю абонента заранее предсказывает риск его ухода, позволяя бизнесу принять превентивные меры (скидки, бонусы).

Целевой пользователь:

Отделы маркетинга, менеджеры по удержанию клиентов (retention-менеджеры) и операторы службы поддержки телеком-провайдера.

Данные

- **Источник:** Открытый датасет Telco Customer Churn (Kaggle).
- **Объём данных:** 7 043 записи.

Ключевые характеристики:

- *Демография:* пол, наличие партнера и иждивенцев, статус пенсионера.
- *Услуги:* тип интернета, телефонная связь, техподдержка, онлайн-безопасность.
- *Финансы и аккаунт:* тип контракта, ежемесячный платеж (MonthlyCharges), срок использования (Tenure).
- **Специфика:** Данные несбалансированы (около 26.6% клиентов ушли, остальные остались).

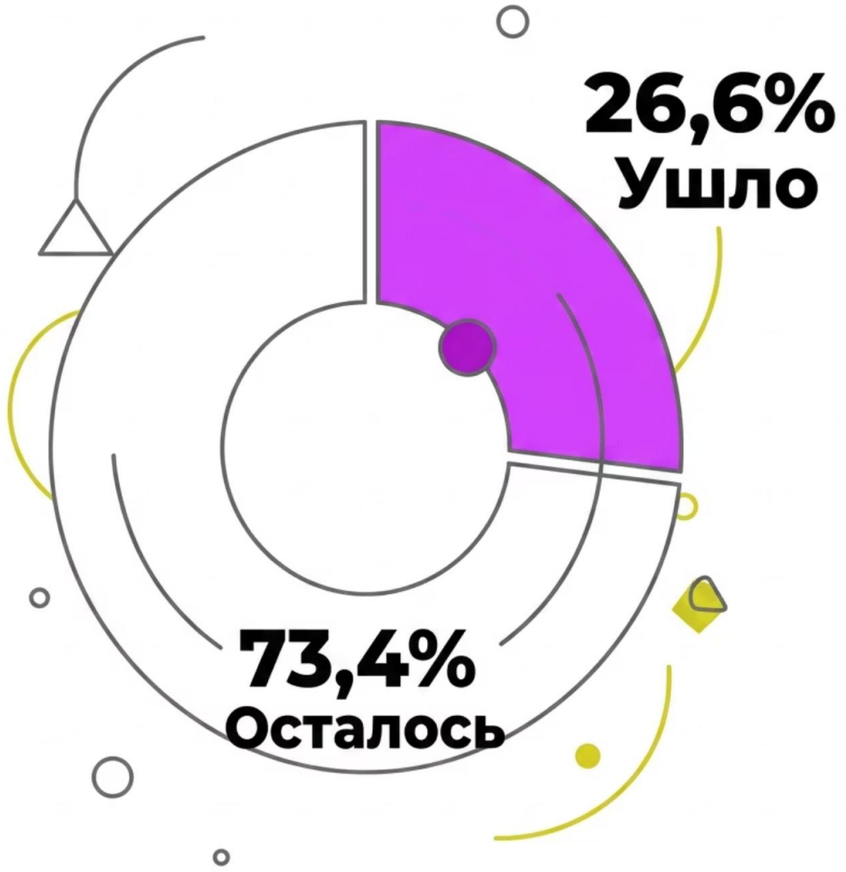

Метод и модель

Подход

Сравнивались базовая эвристика (простое правило по типу контракта) и ряд ML-алгоритмов (Логистическая регрессия, KNN, CatBoost, Random Forest). Для решения проблемы дисбаланса классов применялся метод **SMOTE** и кросс-валидация.

Выбранная модель

Случайный лес с оптимизированными гиперпараметрами (**Random Forest Tuned**).

Почему именно она?

Модель показала наилучший баланс метрик: она не переобучилась на синтетических данных (в отличие от бустингов) и обеспечила отличную интерпретируемость (четко выделяет важность признаков).

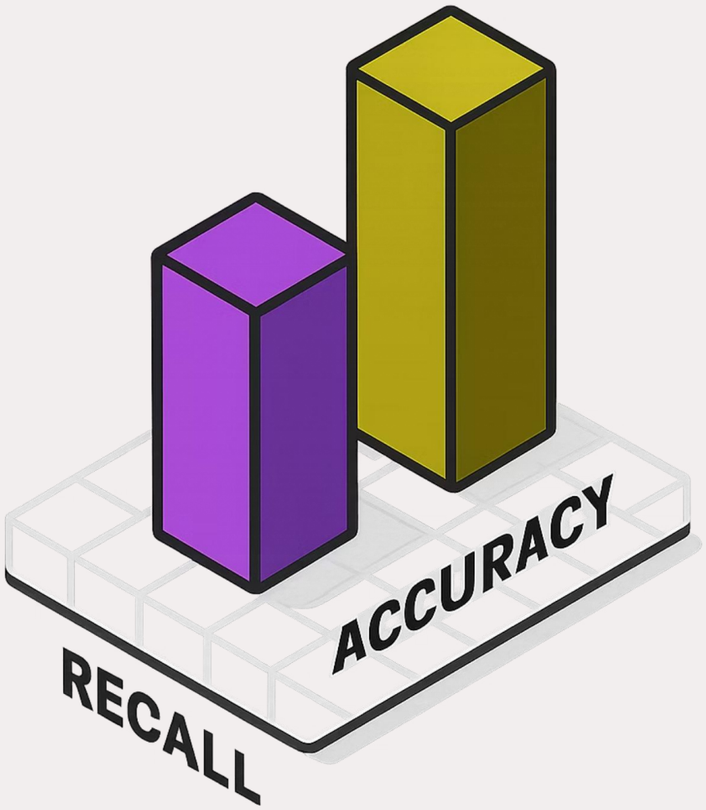

Результаты и трудности

Ключевая метрика:

Фокус был сделан на метрику **Recall** (Полнота) = 0.72, при общей точности (Accuracy) ~82%. Нам важнее минимизировать ложноотрицательные ошибки (не пропустить уходящего клиента).

Что получилось хорошо:

Модель выявила железную логику — чаще всего уходят клиенты с помесячным контрактом, высокими платежами и без услуги «Техподдержка».

Главные трудности:

Основной сложностью был дисбаланс классов. Применение SMOTE повысило Recall, но немного снизило общую точность. Потребовалось найти оптимальный "трейд-офф" между Accuracy и Recall при настройке гиперпараметров (GridSearchCV).

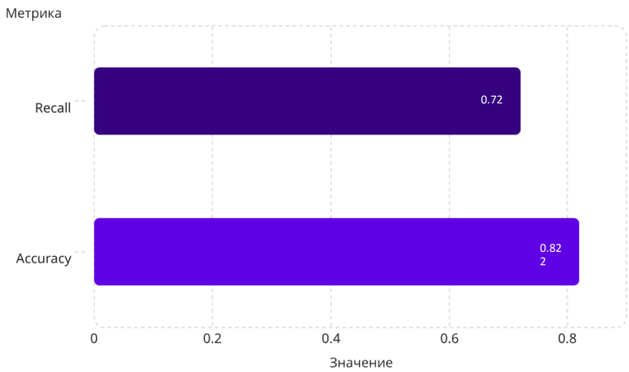

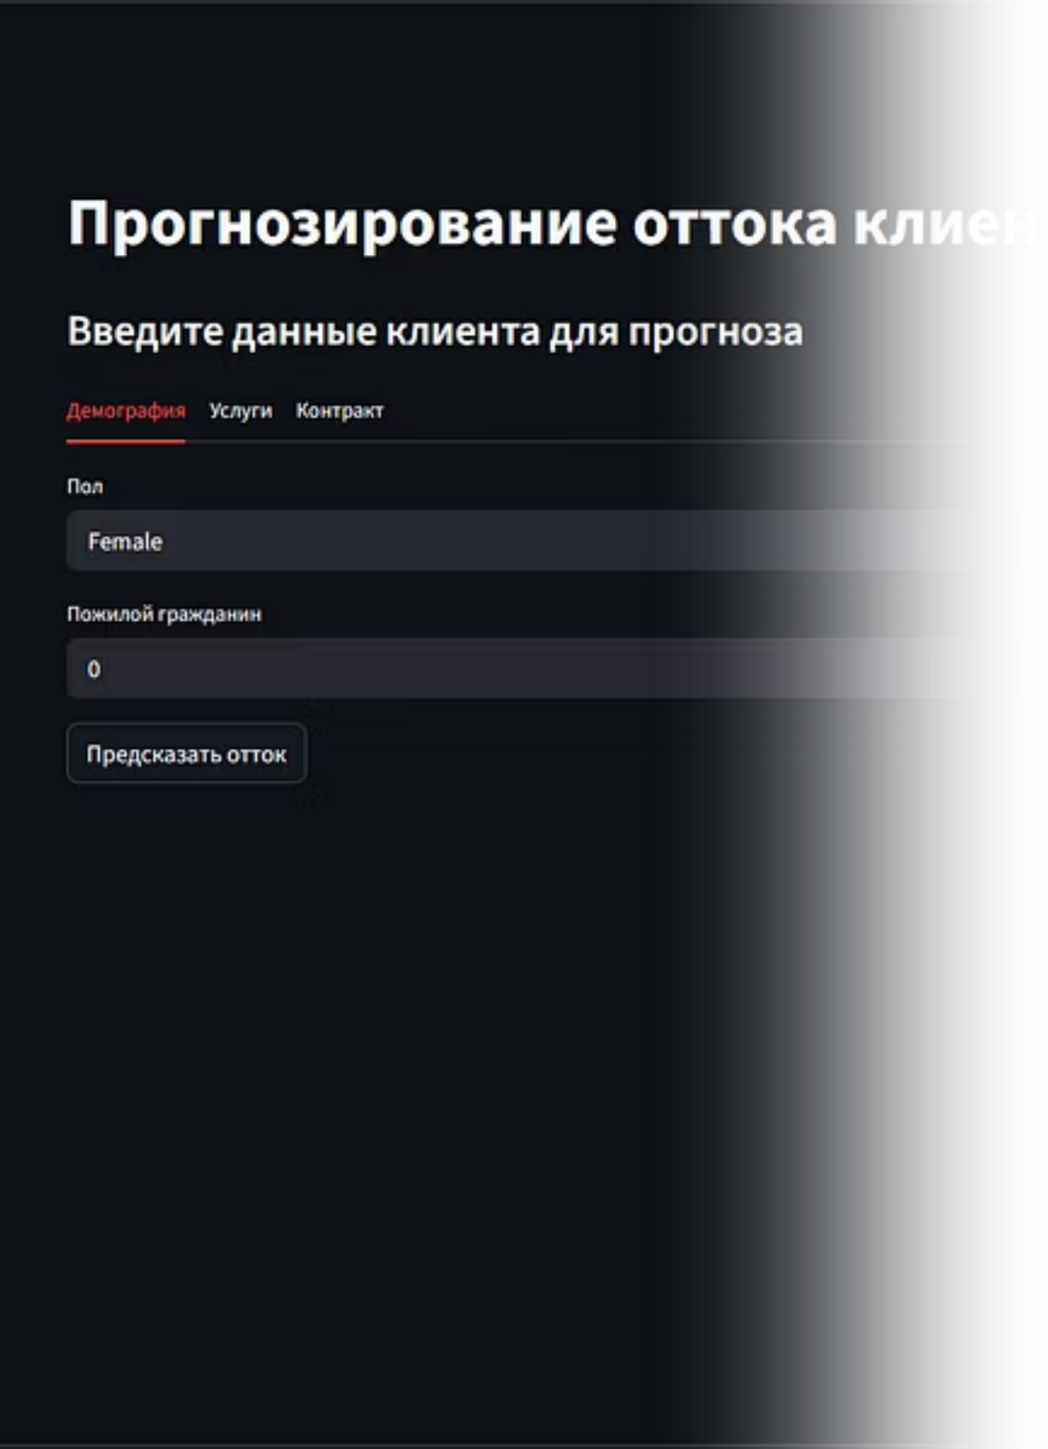

Рабочий прототип и архитектура

Интерфейс:

Разработан веб-прототип на базе фреймворка **Streamlit**. Пользователь вводит параметры клиента через ползунки и выпадающие списки, а система выдает вероятность ухода.

Архитектура проекта:

- train.py — скрипт очистки данных, обучения и сохранения модели (в файл .pkl).
- app.py — запуск Streamlit-интерфейса, подгрузка модели и инференс.
- tests/test_basic.py — набор автоматических тестов (проверка загрузки модели, формата ответа и запуска UI).

Выводы и дальнейшее развитие

Чего достигли:

Полностью реализован пайплайн ML-проекта — от анализа данных и борьбы с дисбалансом до упаковки модели в рабочий веб-интерфейс, покрытый тестами.

Бизнес-вывод:

Главный триггер оттока — помесячные контракты и высокие тарифы без доп. услуг безопасности.

Что можно улучшить:

- Добавить обработку естественного языка (NLP) для анализа отзывов клиентов или логов чата с поддержкой.
- Настроить сбор обратной связи в интерфейсе Streamlit для дообучения модели.
- Завернуть проект в Docker для более удобного деплоя.